


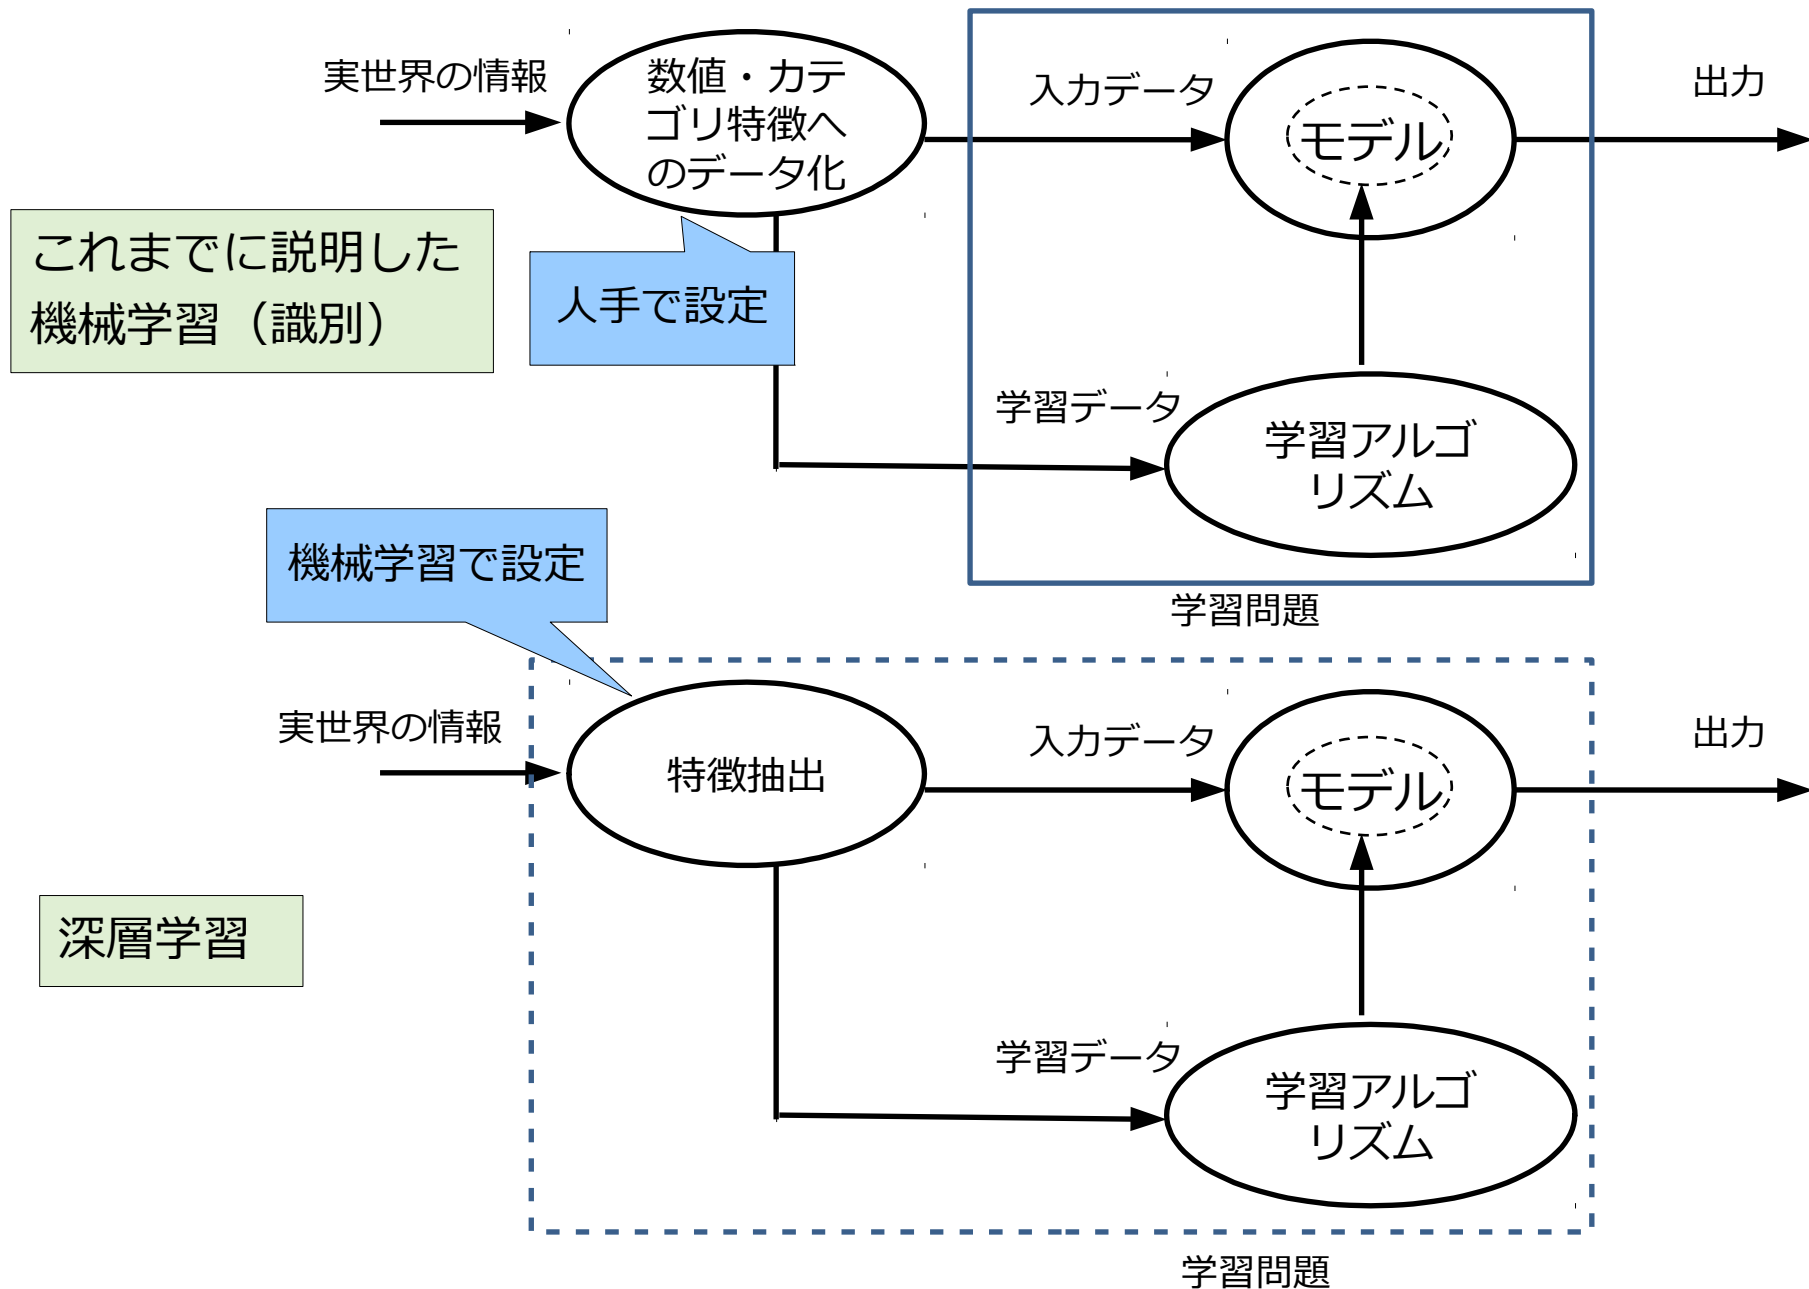
9. 深層学習

9.1 深層学習とは

- 深層学習の定義のひとつ
 - 表現学習：抽出する特徴も学習する



9.1 深層学習とは



9.1 深層学習とは

単純なマルチレイヤーパーセプトロンとの違い

- 多階層学習における工夫
 - 事前学習
 - 活性化関数の工夫
 - 過学習の回避：ドロップアウト
- 問題に応じたネットワーク構造の工夫
 - 畳み込みネットワーク
 - リカレントネットワーク

9.1 深層学習とは

- 深層学習の進展

- 転移学習

- あるタスクにおける表現学習結果を、データが少ない別のタスクに転用

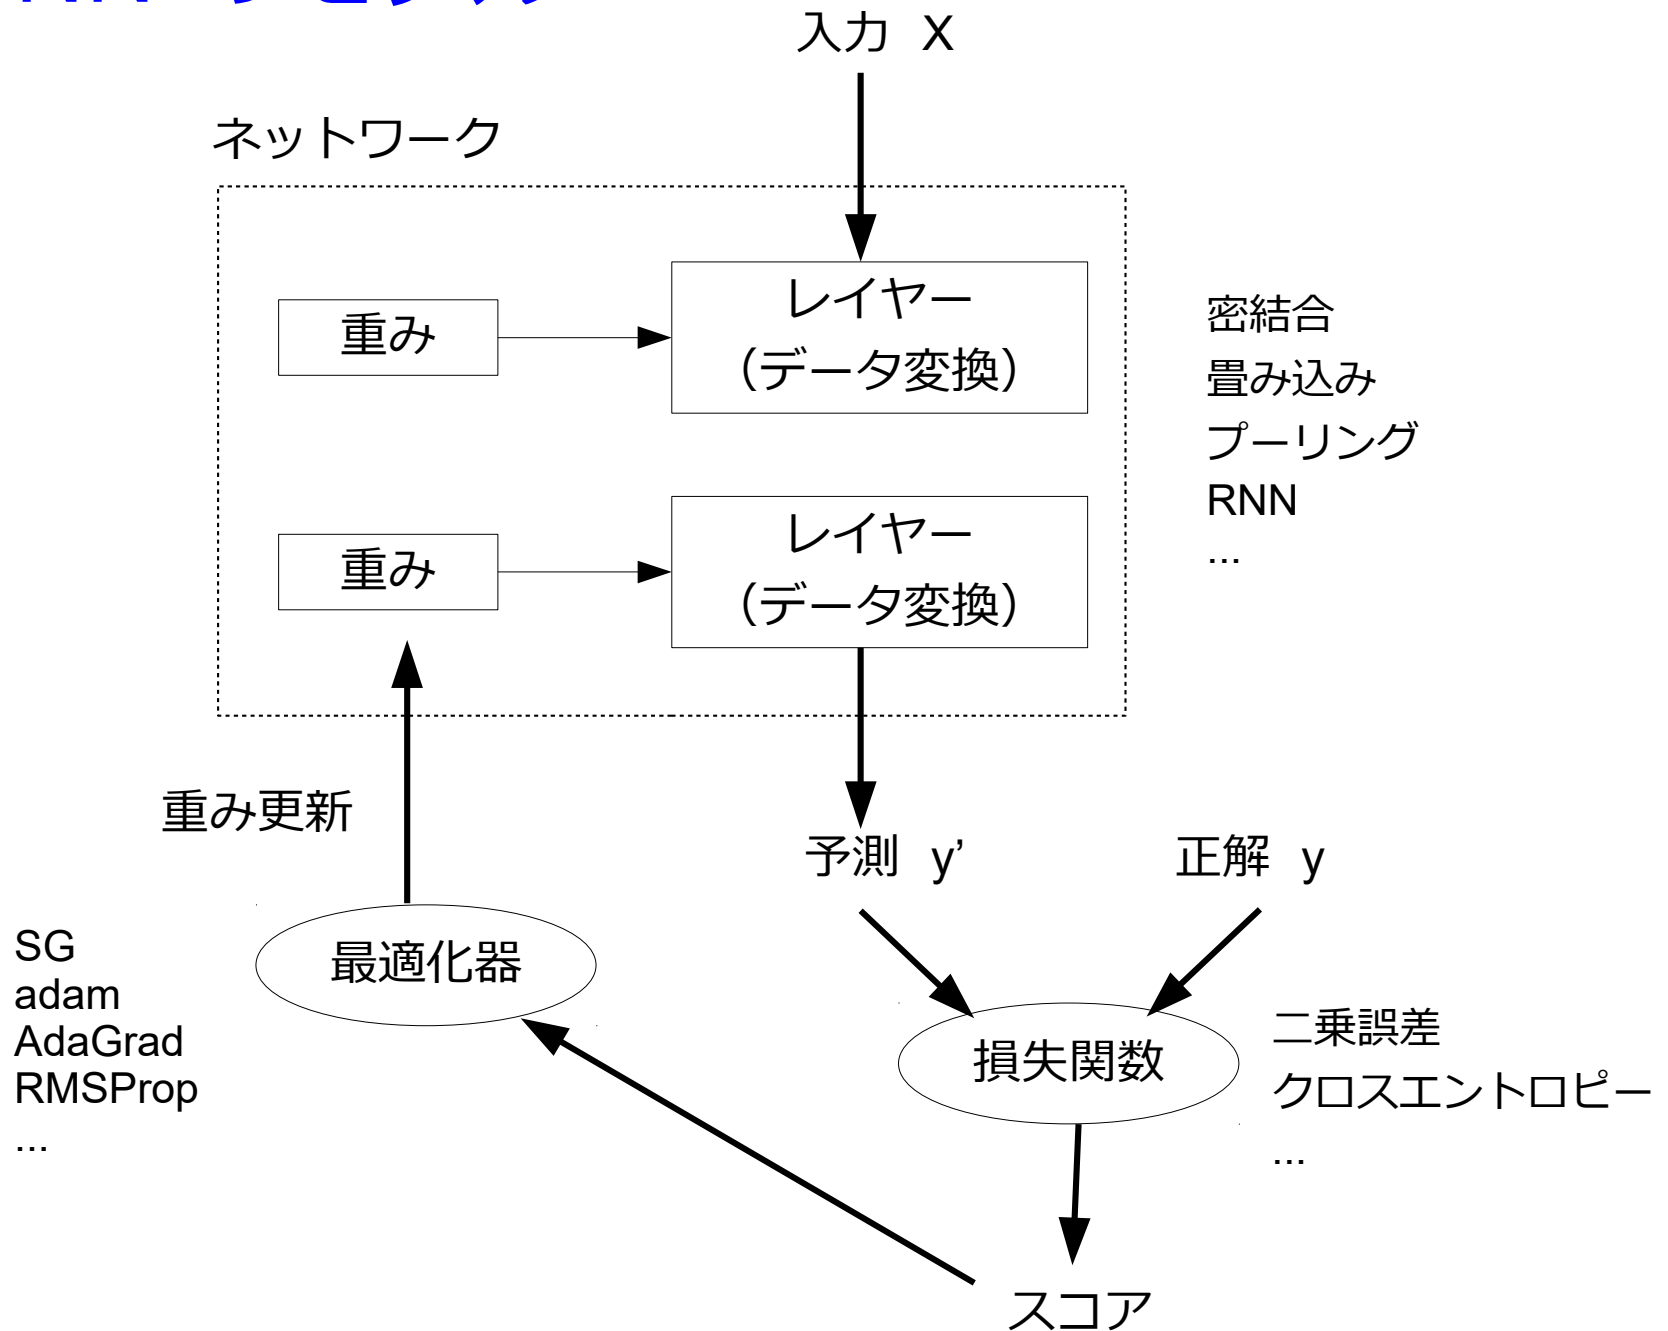
- 生成問題への適用

- 敵対的生成ネットワークによる教師なし学習

- 強化学習への適用

- 深層強化学習

9.2 DNN のモデル




9.3 多階層ニューラルネットワーク

9.3.1 多階層ニューラルネットワークの学習

- 多階層における誤差逆伝播法の問題点
 - 修正量が消失／発散する


順方向：非線形

逆方向：線形



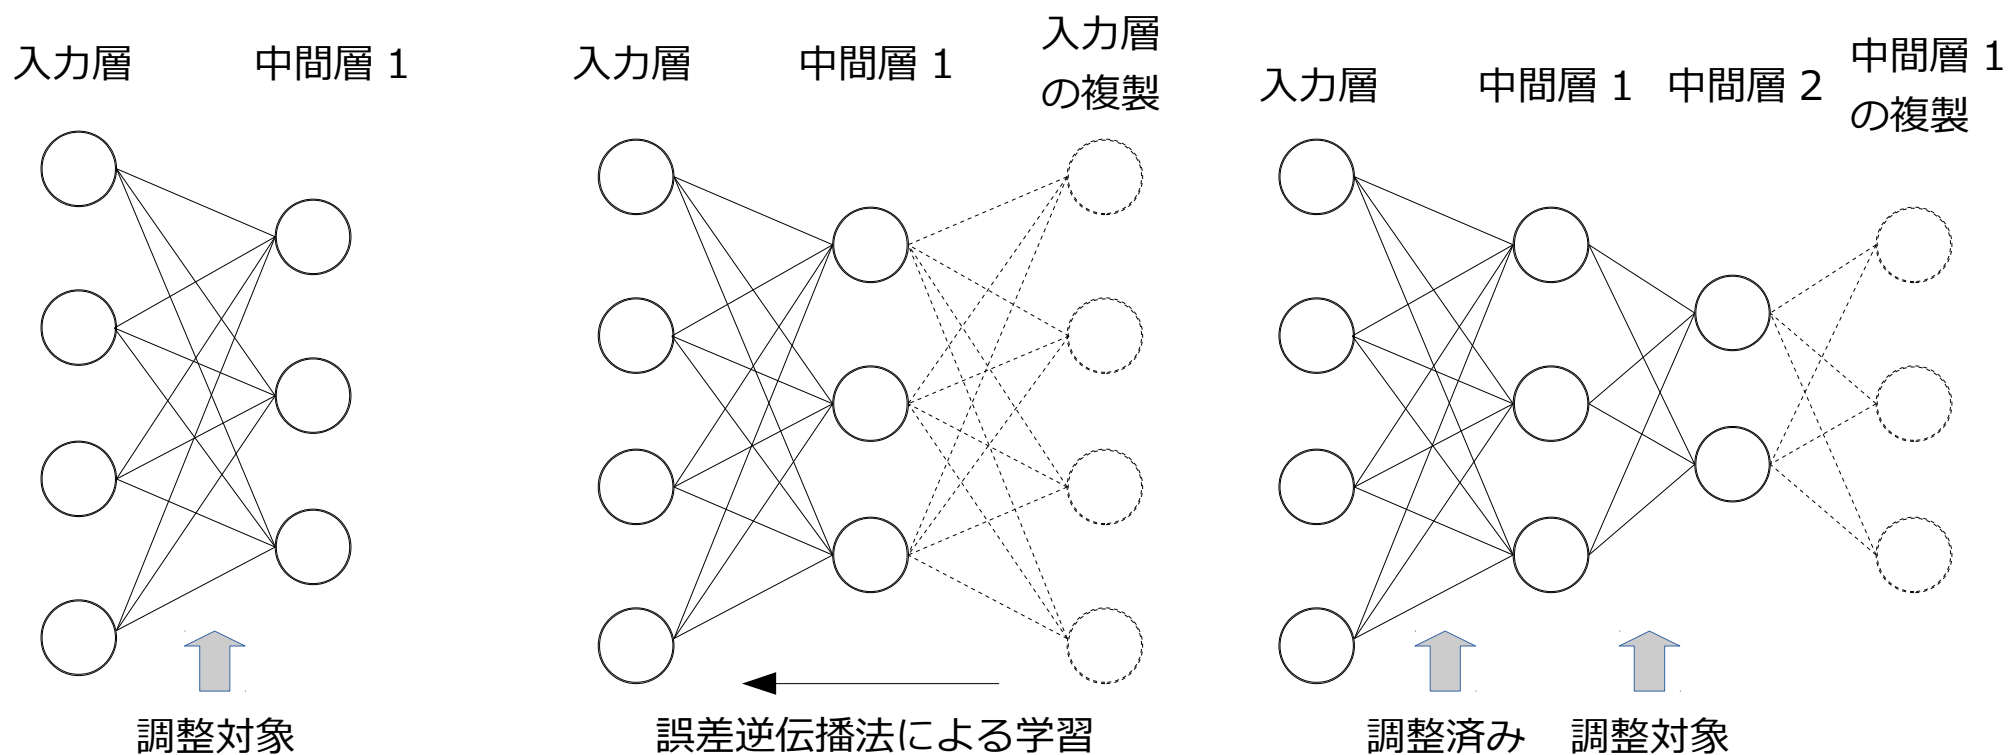
9.3.1 多階層ニューラルネットワークの学習

- 事前学習法のアイデア
 - 深層学習における初期パラメータ学習



9.3.2 オートエンコーダ

- オートエンコーダのアイデア
 - 自己写像を学習する



(a) 事前調整対象の重み


(b) オートエンコーダによる
復元学習

(c) 1 階層上の事前調整


9.3.3 多階層学習の工夫

- 活性化関数を rectified linear 関数に ➡ RELU

$$f(x) = \max(0, x)$$



(a) rectified linear 関数




(b) (a) の導関数

- RELU の利点
 - 誤差消失が起こりにくい
 - 0 を出力するユニットが多くなる


9.3.3 多階層学習の工夫

- 活性化関数を双曲線正接 tanh 関数に

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^{-x} + e^x}$$



(a) tanh 関数



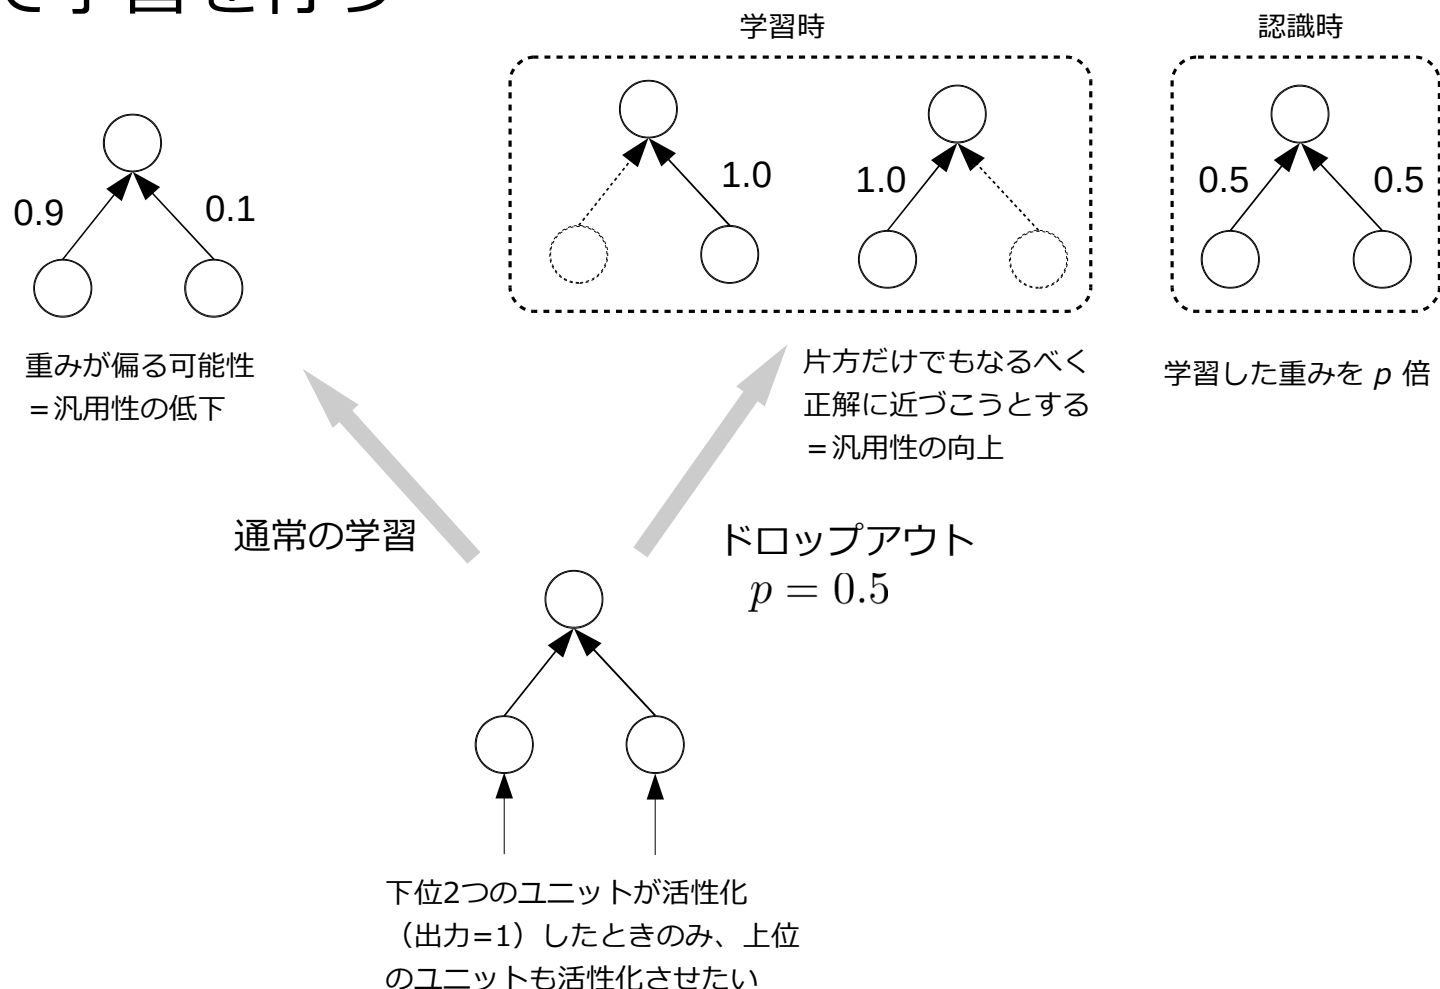
(b) (a) の導関数

- tanh の利点
 - 誤差消失が起こりにくい
- cf) sigmoid は微分係数の最大値が 0.25

9.3.3 多階層学習の工夫


- 過学習の回避

- ドロップアウト：ランダムに一定割合のユニットを消して学習を行う



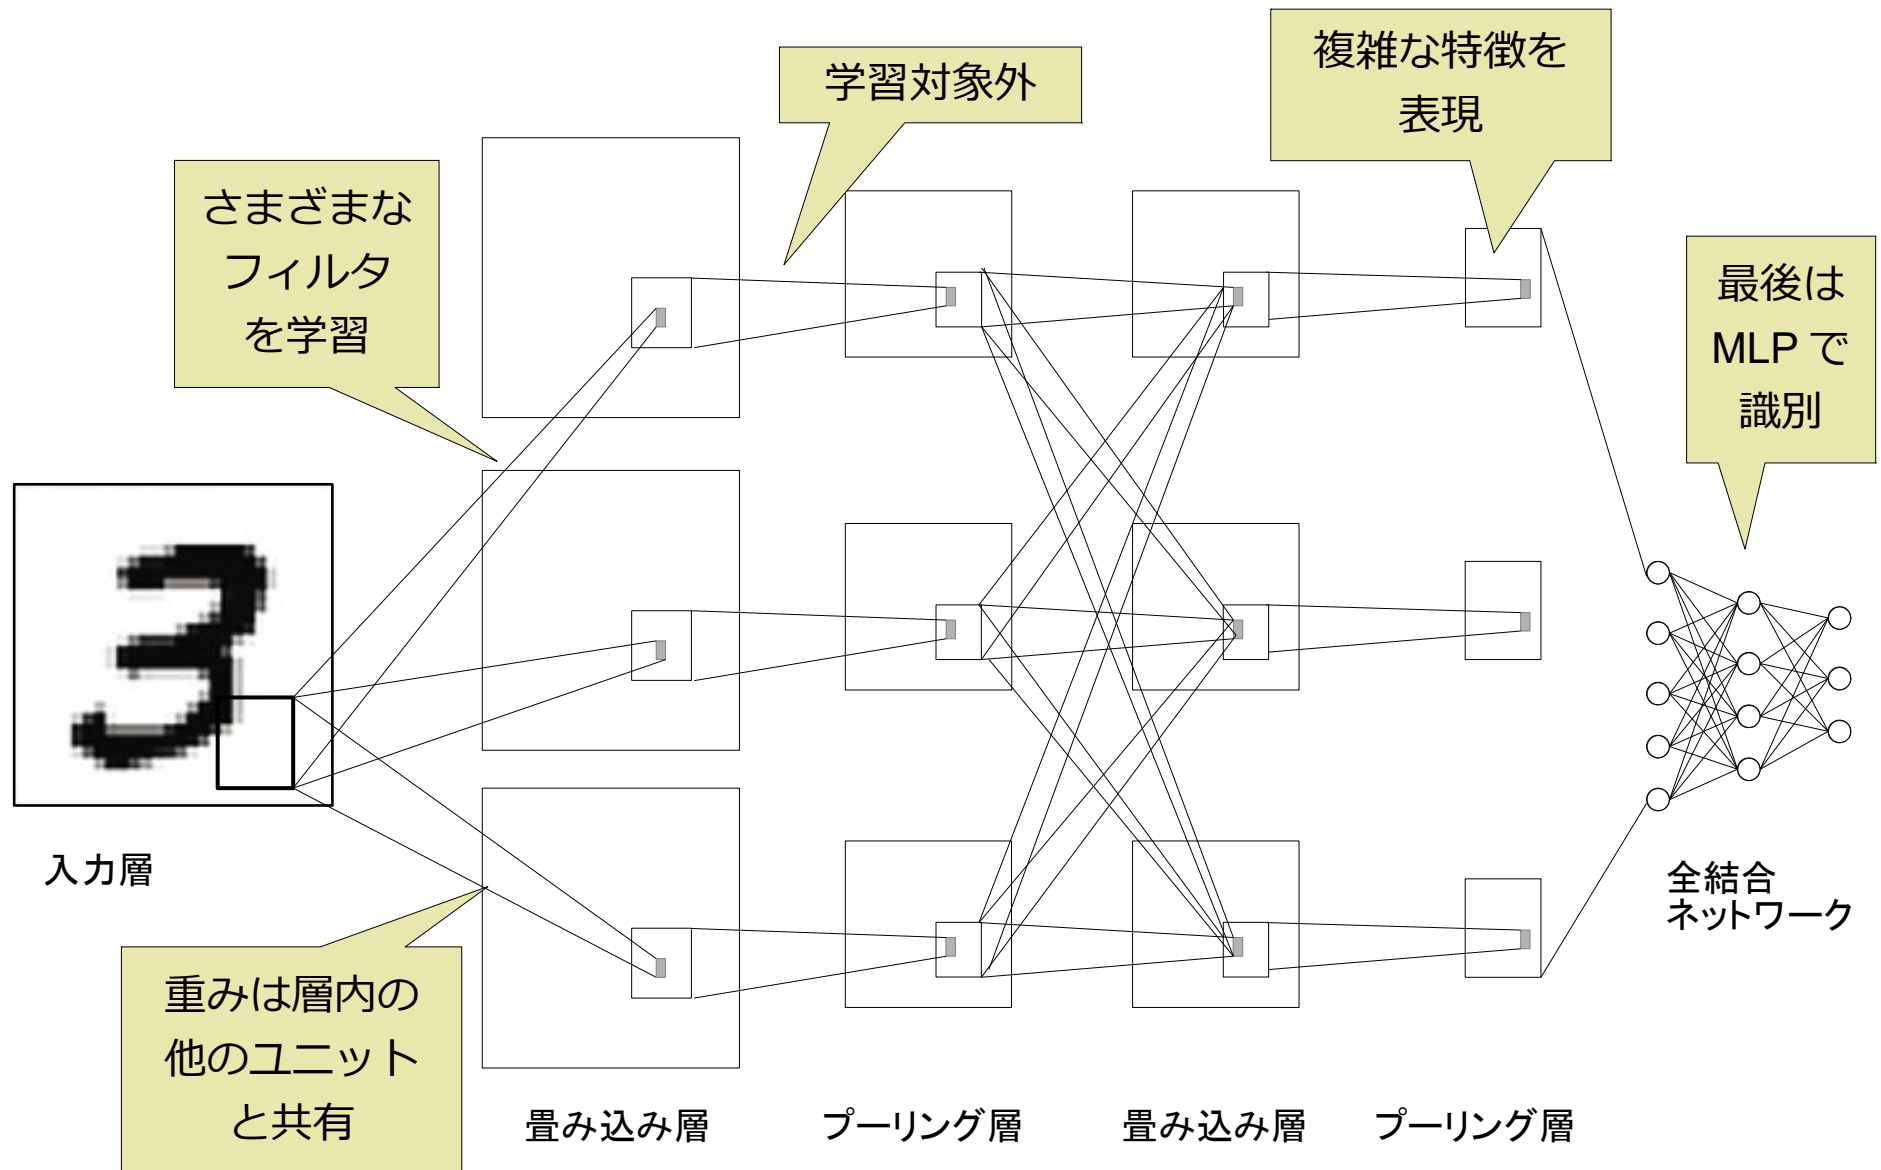
9.4 畳み込みネットワーク

- 畳み込みニューラルネットワークの構造
 - 畳み込み層とプーリング層を交互に重ねる
 - 畳み込み層はフィルタの画素数・ずらす画素数・チャンネル数の情報からなる
 - 最後は通常の MLP (Relu+softmax)



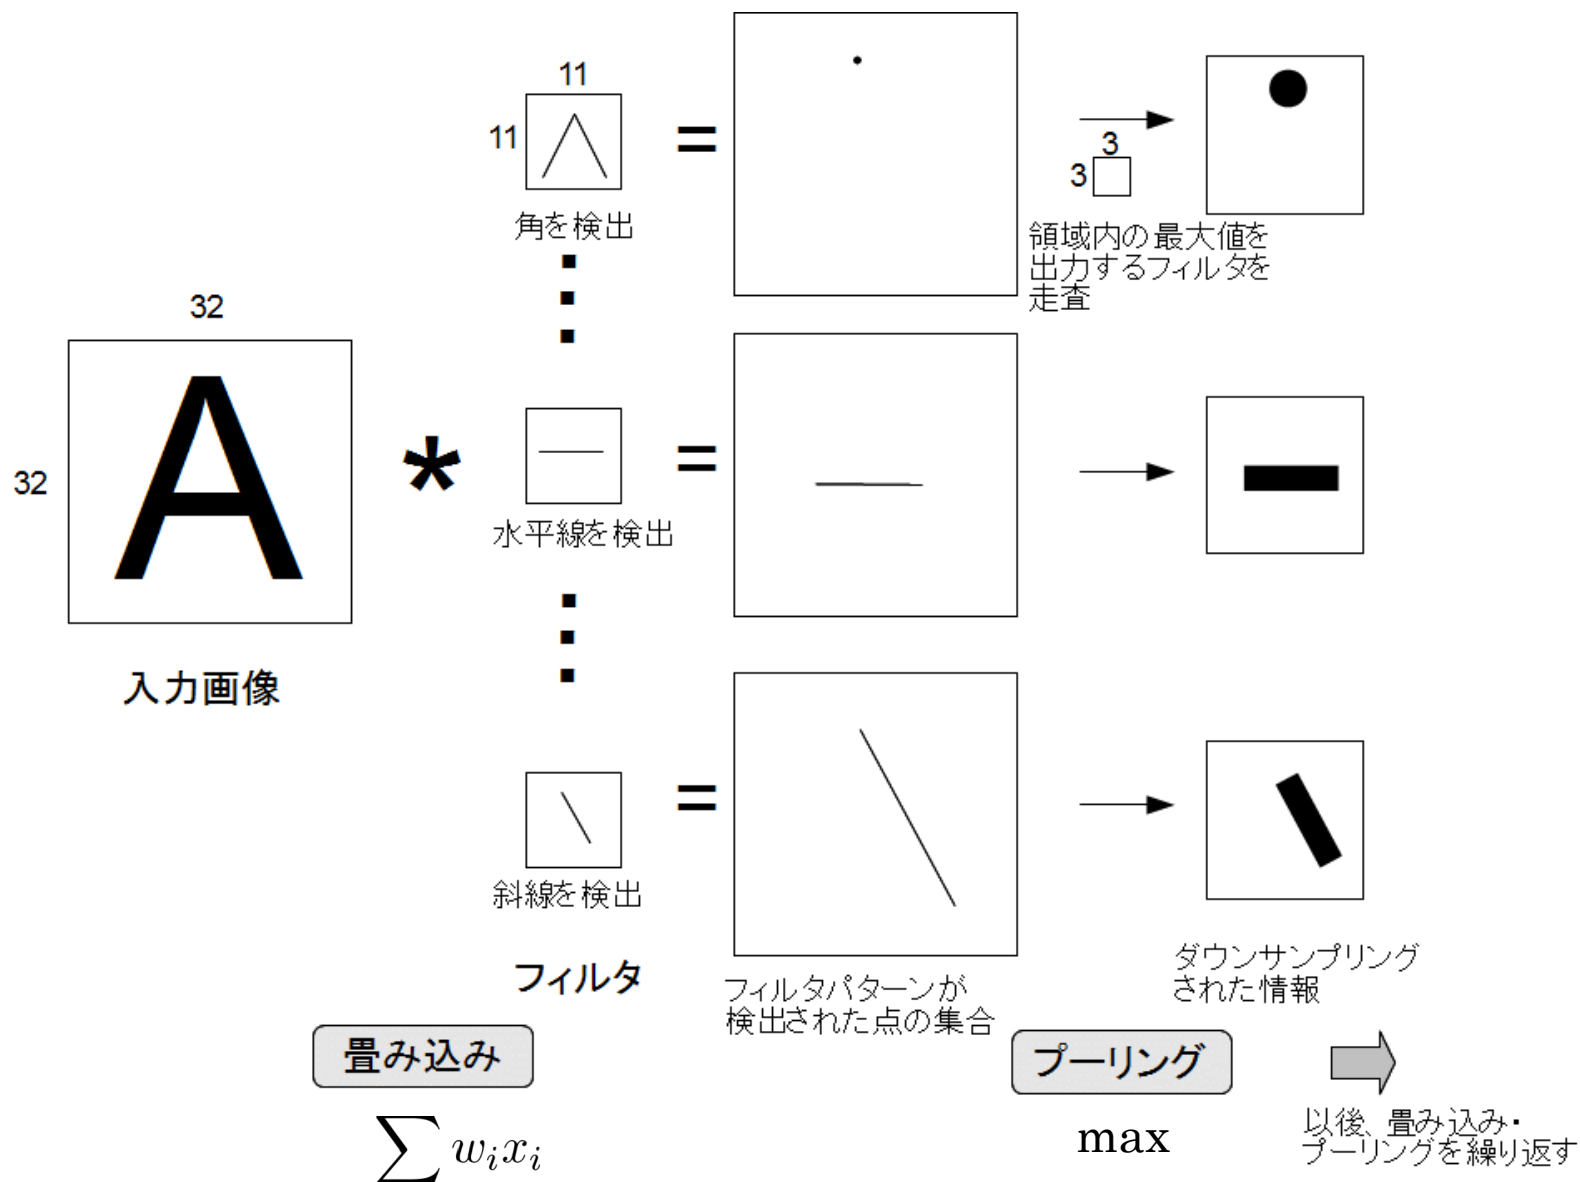
9.4 畳み込みネットワーク

• 畳み込みニューラルネットワークにおける学習



9.4 畳み込みネットワーク

• 畳み込みニューラルネットワークの演算




9.4 畳み込みニューラルネットワーク

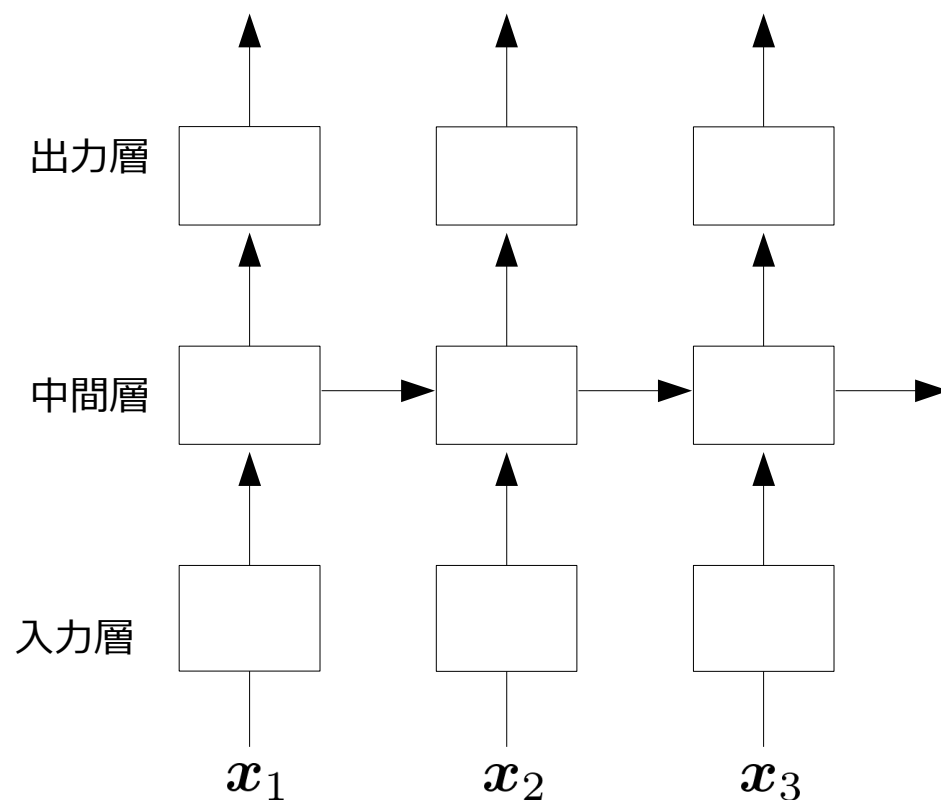
- バッチ標準化の必要性
 - 入力データが標準化されていることは前提
 - 多階層のネットワークで演算を行うと、それぞれの階層の出力が適切な範囲に収まっているとは限らない（たとえば正の大きな値ばかりかもしれない）
- 標準化演算
 - 平均値を引いて標準偏差で割る
 - 1 層のネットワークで実現可能

9.5 リカレントニューラルネットワーク

- 時系列信号の認識や自然言語処理に適する



(a) リカレントニューラルネットワーク



(b) 帰還路を時間方向に展開

9.5 リカレントニューラルネットワーク

- リカレントネットワークの学習

- 通常 of 誤差逆伝播法の更新式

$$w'_{ji} \leftarrow w_{ji} + \eta \delta_j x_{ji}$$

に対して、時間を遡った更新が必要


- 時刻 t において、 k 個過去に遡った更新式

$$w_{ji}(t) \leftarrow w_{ji}(t-1) + \sum_{z=0}^k \eta \delta_j(t-z) x_{ji}(t-z-1)$$

- 勾配消失を避けるため、 $k=10 \sim 100$ 程度とする

9.5 リカレントニューラルネットワーク

- LSTM (long short-term memory)
 - いくつかのゲートからなる内部構造をもつユニット
 - ゲート：選択的に情報を通すメカニズム



- 参考サイト

<http://colah.github.io/posts/2015-08-Understanding-LSTMs/>

9.5 リカレントニューラルネットワーク


- LSTM のゲート

- 忘却ゲート：セルの内容を捨てるかどうか
 - 例) 言語モデルにおいて、新たな主語が現れた場合、古い主語の性別は捨てる
- 入力ゲート：セルの内容のどの部分を更新するか
 - 例) 古い主語の性別を新たな主語の性別で置き換える
- 出力ゲート：セルの内容のどの部分を出力するか
 - 例) 主語に続く動詞の形を決めるために、主語の単複を出力

9.5 リカレントニューラルネットワーク

- Bidirectional RNN

- 過去だけでなく、未来の情報も用いて出力を計算

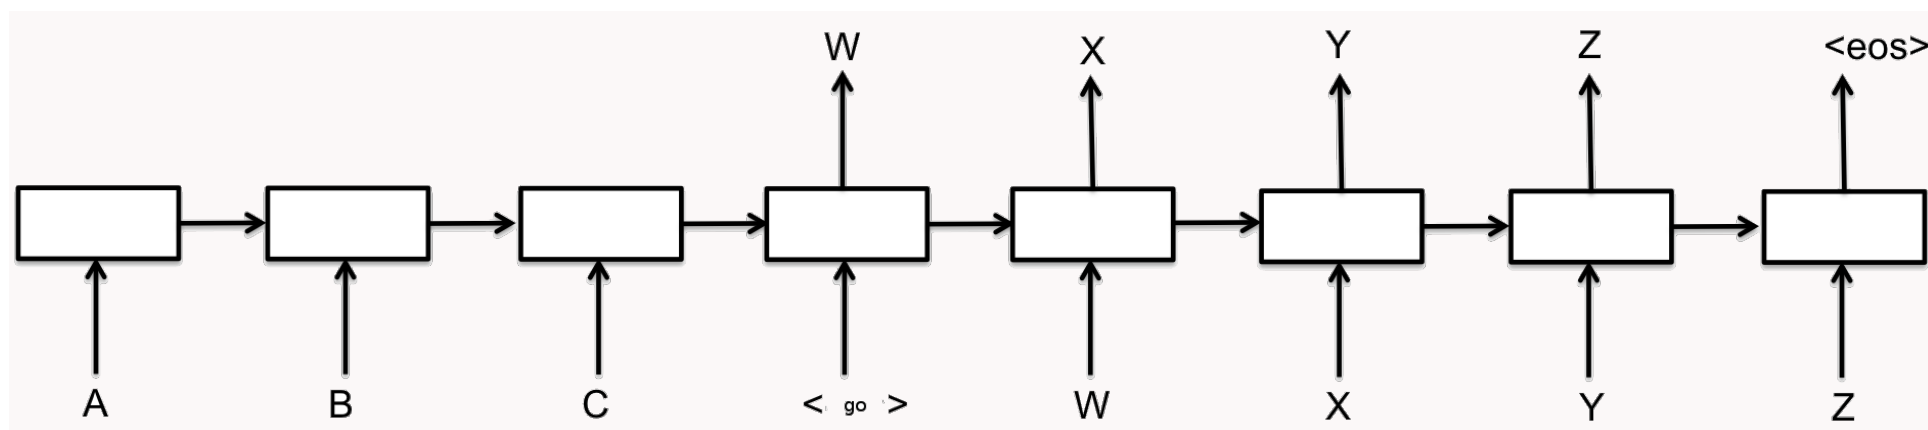


He, L., Qian, Y., Soong, F.K., Wang, P., & Zhao, H. (2015). A Unified Tagging Solution: Bidirectional LSTM Recurrent Neural Network with Word Embedding. CoRR, abs/1511.00215.

9.5 リカレントニューラルネットワーク

- Encoder-Decoder

- 入力の内容をひとつの表現にまとめて、そこから出力を生成



arXiv:1406.1078